CP2/CP3 · Generative AI for Engineering · 4ESPY-2026

Sentimento por aspecto em avaliações de produtos com Qwen3-1.7B + LoRA

Fine-tuning de uma LLM local em GPU (Apple M5 · Metal/MPS), comparação de hiperparâmetros, avaliação das respostas e frontend para o usuário criar o prompt.

Professor: Francisco Elanio

Integrantes do grupo

Nome	RM
Felipe Cortez	99750
Julia Lins	98690
Luis Barreto	99210
Victor Aranda	99667
Guilherme Akio	98582

Repositório: https://github.com/lgustavobarre351/GENERATIVE_AI_CP2-CP3

Data de entrega: 15/10/2026

Resultado principal	Modelo sem treino	Modelo treinado (LoRA)
Acerto exato · 400 avaliações com frases inéditas	25,5%	**83,0%**
F1 dos pares (aspecto, sentimento)	0,514	**0,926**
Acerto exato · 40 avaliações escritas à mão	27,5%	**82,5%**

Sumário

1. Requisitos da atividade e onde estão atendidos
2. Problema escolhido
3. LLM escolhida e técnica de treino
4. Dados
5. Como o sistema funciona
6. Ambiente e GPU
7. Experimentos (parâmetros testados)
8. Metodologia de avaliação
9. Resultados
10. Conclusões sobre os parâmetros
11. Avaliação das respostas
12. Frontend
13. Entregáveis
14. Limitações e próximos passos
15. Referências

1. Requisitos da atividade e onde estão atendidos

Requisito do enunciado	Como foi atendido	Seção
Treinar uma LLM local	Qwen3-1.7B treinado com LoRA localmente, sem nenhuma API externa	3, 7
Selecionar/escolher a LLM	Qwen3-1.7B (lista sugerida pelo professor), com justificativa	3
Escolher um problema específico	Sentimento por aspecto (lista sugerida pelo professor)	2
Testar diferentes parâmetros	7 configurações: rank do LoRA, learning rate, épocas e camadas, mais o baseline	7, 9, 10
Verificar/avaliar o modelo (respostas)	6 métricas em 2 conjuntos de teste, matrizes de confusão e as respostas de cada exemplo	8, 9, 11
Fazer todos os testes utilizando GPU	Todos os treinos e avaliações na GPU do Apple M5 (Metal/MPS), autorizada pelo professor	6
Criar um frontend para o usuário inserir/criar o prompt	App Gradio com 4 abas, incluindo 'Prompt livre'	12
Print da GPU instalada e funcionando no VSCode	Print com informações da GPU e monitor a 98% de uso	6
Documentação e código no GitHub	https://github.com/lgustavobarre351/GENERATIVE_AI_CP2-CP3	13
Grupo de 4 a 5 pessoas	5 integrantes	Capa

2. Problema escolhido: sentimento por aspecto

Problema da lista sugerida pelo professor (categoria *Classificação*). Dada uma avaliação de produto escrita em português, o modelo identifica o sentimento de **cada aspecto mencionado** e responde em JSON:

```
"Entrega rápida, mas o produto veio arranhado e achei caro."
→ {"entrega": "positivo", "qualidade": "negativo", "preço": "negativo"}
```

- **Aspectos:** entrega, qualidade, preço, atendimento, embalagem.
- **Sentimentos:** positivo, negativo, neutro.
- Aspectos não mencionados ficam fora do JSON. Sem nenhum aspecto, a resposta é `{}`.

Por que esse problema? Um sentimento geral esconde informação: uma avaliação de 3 estrelas pode elogiar o produto e reclamar da transportadora. Separar por aspecto mostra **onde** está o problema (logística, fornecedor, preço, SAC, embalagem). Além disso, a resposta tem formato fixo e é **verificável automaticamente**, campo a campo, o que permite comparar configurações de treino de forma objetiva.

3. LLM escolhida e técnica de treino

Critério	Qwen3-1.7B
Lista do professor	Qwen3 (0.6B, **1.7B**, 4B, 8B)
Português	Modelo multilíngue, com bom desempenho em PT-BR
Tamanho	1,7 bilhão de parâmetros: cabe e treina com LoRA na GPU de um notebook (Apple M5, 16 GB)
Formato de saída	Segue instruções e gera JSON. O modo de raciocínio (`<think>`) foi desligado para respostas diretas
Licença	Apache 2.0

LoRA (Low-Rank Adaptation). Em vez de atualizar os 1,7 bilhão de pesos, o modelo original fica congelado e treinamos pequenas matrizes de baixo rank inseridas nas camadas lineares. Na configuração final (r=16), são 17.4 milhões de parâmetros treináveis (1.0% do total), e o adaptador resultante tem 33 MB.

4. Dados

Seguindo a sugestão do professor, os dados são **sintéticos e com verificação exata**, gerados por `src/data.py`:

- Banco de 184 frases escritas à mão (5 aspectos × 3 sentimentos), combinadas com conectivos de contraste ("mas", "porém", "por outro lado"...).
- Frases sem aspecto ("Comprei para dar de presente.", "Recomendo!"), que o modelo deve ignorar.
- Ruído de texto real: 25% das avaliações em minúsculas e 15% sem acentos.
- Cada avaliação tem de 0 a 4 aspectos.

Conjunto	Exemplos	Observação
Treino	2000	Frases do "banco de treino" (75% das frases de cada aspecto/sentimento)
Validação	200	Mesmo banco do treino; usado para a loss de validação
Teste	400	**Somente frases que nunca aparecem no treino** (25% restantes)
Teste manual	40	Escritas à mão, com linguagem natural, gírias e abreviações ("tá", "pq", "mt"), fora do gerador

O teste manual mede se o modelo generaliza para avaliações reais, e não apenas para o padrão do gerador. Exemplos do conjunto de treino:

Avaliação	Resposta esperada (JSON)
A embalagem é discreta; no entanto, a bateria não dura nada, porém a entrega foi no prazo normal. Vou usar na casa de praia.	`{"entrega": "neutro", "qualidade": "negativo", "embalagem": "neutro"}`
veio muito bem embalado. além disso, fui muito bem atendido. estava precisando de um desses.	`{"atendimento": "positivo", "embalagem": "positivo"}`
o frete foi rapidissimo. pesquisei bastante antes de comprar.	`{"entrega": "positivo"}`
A caixa chegou toda amassada, o vendedor foi grosseiro, só que o frete foi rapidíssimo!	`{"entrega": "positivo", "atendimento": "negativo", "embalagem": "negativo"}`
É a segunda vez que compro. Chegou antes do prazo. A embalagem é reforçada, com plástico bolha. A qualidade superou minhas expectativas, comprei em promoção e valeu muito a pena.	`{"entrega": "positivo", "qualidade": "positivo", "preço": "positivo", "embalagem": "positivo"}`
A caixa chegou intacta.	`{"embalagem": "positivo"}`

5. Como o sistema funciona

`avaliação → prompt (system + chat template do Qwen3) → Qwen3-1.7B + LoRA → JSON {aspecto: sentimento}`

- **Prompt:** o *system prompt* lista os aspectos, os sentimentos e o formato, com um exemplo. O mesmo prompt é usado no modelo sem treino (baseline), para a comparação ser justa.
- **Treino:** a loss é calculada **somente nos tokens da resposta** (o JSON); o prompt é mascarado.
- **Inferência:** geração determinística (greedy) em lotes. A resposta passa por um parser que valida o JSON e descarta aspectos ou sentimentos fora da lista.

System prompt utilizado:

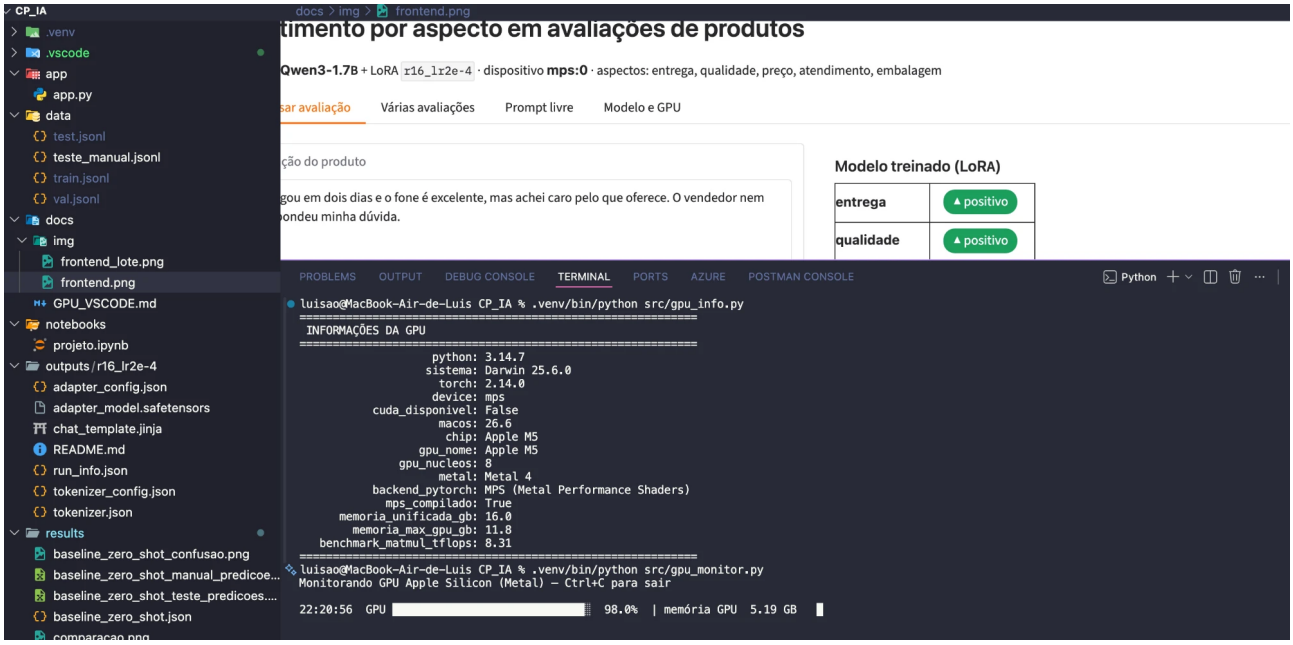
```
Você analisa avaliações de produtos escritas em português e identifica o sentimento de cada
aspecto mencionado.
Aspectos possíveis: entrega, qualidade, preço, atendimento, embalagem.
Sentimentos possíveis: positivo, negativo, neutro.
Responda somente com um JSON em que cada chave é um aspecto mencionado e o valor é o sentimento
dele. Inclua apenas os aspectos mencionados na avaliação. Se nenhum aspecto for mencionado,
responda {}.
Exemplo: "Paguei barato, mas a tampa quebrou." -> {"qualidade": "negativo", "preço": "positivo"}
```

Observação: na primeira versão, o prompt dizia apenas `{"aspecto": "sentimento"}`, e o modelo base interpretou literalmente, respondendo `{"aspecto": "entrega", "sentimento": ...}`. Um exemplo concreto foi adicionado ao prompt para o baseline ser avaliado de forma justa (100% de JSON válido).

6. Ambiente e GPU

Todos os treinos e avaliações foram executados na **GPU integrada do Apple M5**, via backend **MPS (Metal Performance Shaders)** do PyTorch. O uso de Metal no lugar de CUDA foi autorizado pelo professor, já que o computador do grupo não tem placa NVIDIA. O código também roda em CUDA sem alterações: `src/config.py` escolhe automaticamente CUDA → MPS → CPU.

Item	Valor
Chip / GPU	Apple M5 · 8 núcleos de GPU
API gráfica	Metal 4
Backend PyTorch	MPS (Metal Performance Shaders)
Memória unificada	16 GB (até 11.8 GB disponíveis para a GPU)
Benchmark (multiplicação de matrizes fp16)	12.45 TFLOPS
Sistema	macOS 26.6
Software	Python 3.14.7 · PyTorch 2.14.0 · Transformers 5 · PEFT 0.21



Print da GPU instalada e funcionando dentro do VSCode: à esquerda, o projeto; em cima, o frontend aberto; embaixo, a saída de src/gpu_info.py e o monitor ao vivo (src/gpu_monitor.py) com a GPU a 98%.

Metal × CUDA

	NVIDIA	Apple Silicon (usado)
API da GPU	CUDA + cuDNN	Metal + Metal Performance Shaders
Dispositivo no PyTorch	torch.device("cuda")	torch.device("mps")
Instalação	Driver NVIDIA + PyTorch com a versão de CUDA compatível	macOS 12.3+ e o PyTorch padrão do PyPI
Memória	VRAM dedicada	Memória unificada (CPU e GPU compartilham os 16 GB)
Monitoramento no VSCode	nvidia-smi, extensões GPU Monitor / GPU Environment	src/gpu_monitor.py (lê o driver via ioreg)

As extensões GPU Monitor e GPU Environment dependem do `nvidia-smi` e só funcionam com NVIDIA. Por isso, foi criado o `src/gpu_monitor.py`, que mostra a utilização e a memória da GPU ao vivo no terminal do VSCode. Ele também detecta NVIDIA e passa a usar o nvidia-smi.

Otimizações de desempenho aplicadas (aprendidas durante a execução)

Problema observado	Solução	Efeito
Treino em fp32 muito lento	Modelo base em bf16, pesos do LoRA em fp32	4× mais rápido, mesma loss
Batch 8 fazia o Mac usar swap	Batch 4 + acumulação de gradiente 4 (batch efetivo 16)	2,7× mais rápido
Velocidade caía de 13 para 42 s/passo ao longo do treino	Padding em múltiplos de 32 e limpeza do cache do MPS a cada 10 passos	Estável em ~14 s/passo
Sem gradient checkpointing, a memória estourava	Gradient checkpointing ligado	Cabe nos ~11,8 GB da GPU
Na bateria, o Mac suspendeu e o treino parou	Treino na tomada; experimentos retomáveis (pulam o que já terminou)	Nenhuma perda de progresso

7. Experimentos (parâmetros testados)

Configuração de referência: LoRA r=16, α=32, dropout 0,05, learning rate 2e-4, 1 época, LoRA em todas as camadas lineares (q, k, v, o, gate, up, down), batch efetivo 16, scheduler cosseno com 5% de warmup, bf16, gradient checkpointing. Cada experimento muda **um único parâmetro** em relação à referência, para isolar o seu efeito.

Experimento	Parâmetro alterado	Hipótese
baseline_zero_shot	Sem treino	Ponto de partida
r16_lr2e-4	Referência	—
r4_lr2e-4 / r64_lr2e-4	Rank do LoRA: 4 / 64	Rank maior = mais capacidade e mais parâmetros treináveis
r16_lr2e-5 / r16_lr1e-3	Learning rate 10× menor / 5× maior	LR baixo aprende pouco; LR alto pode ficar instável
r16_lr2e-4_ep2	2 épocas	Mais épocas podem melhorar ou causar overfitting
r16_lr2e-4_attn	LoRA só na atenção (q, k, v, o)	Menos parâmetros; mede a importância das camadas MLP

8. Metodologia de avaliação

Métrica	O que mede
JSON válido	% de respostas no formato correto
Acerto exato	% de avaliações com **todos** os aspectos e sentimentos certos, sem aspectos a mais
F1 dos pares (principal)	F1 micro dos pares (aspecto, sentimento)
F1 de detecção	Se o modelo encontra os aspectos mencionados, ignorando o sentimento
Acurácia de polaridade	Entre os aspectos detectados, quantos sentimentos estão certos
F1 por aspecto e matriz de confusão	Onde o modelo erra

As respostas de cada modelo para cada exemplo ficam salvas em `results/<experimento>_<conjunto>_predicoes.csv` (texto, esperado, resposta crua do modelo, previsto e se acertou), para a análise qualitativa da seção 11.

9. Resultados

Baseline × melhor modelo

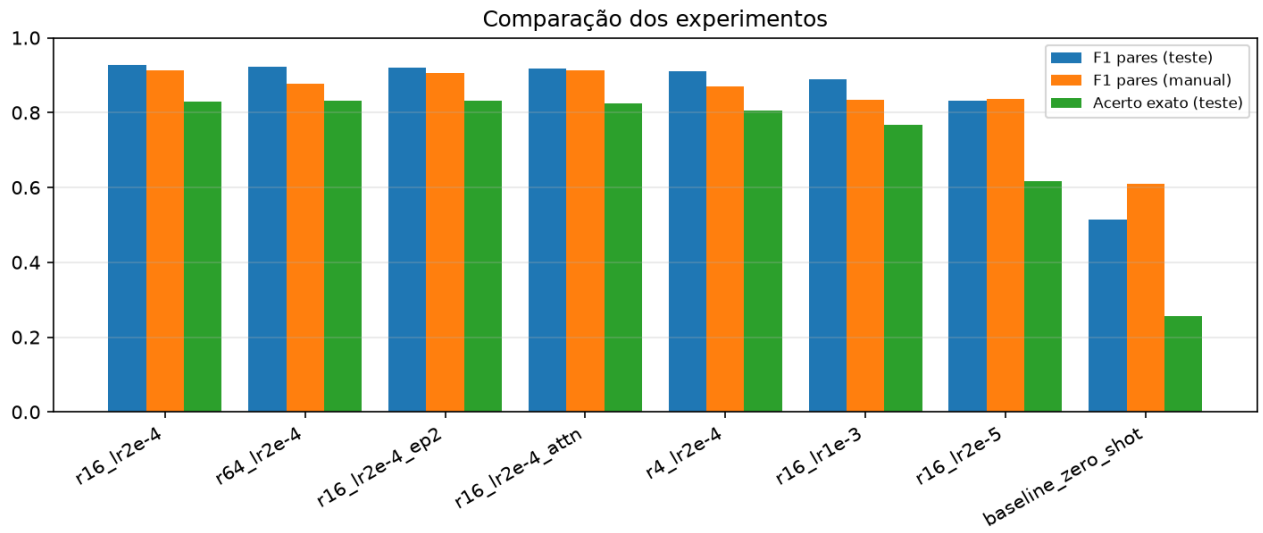
Métrica	Qwen3-1.7B sem treino	Qwen3-1.7B + LoRA (r16_lr2e-4)
JSON válido (teste)	100%	100%
Acerto exato (teste, 400 frases inéditas)	25,5%	**83,0%**
F1 dos pares (teste)	0,514	**0,926**
F1 de detecção de aspectos (teste)	0,707	0,957
Acurácia de polaridade (teste)	72,7%	96,8%
Acerto exato (manual, 40 escritas à mão)	27,5%	**82,5%**
F1 dos pares (manual)	0,611	**0,913**
Tempo de inferência	325 ms/avaliação	365 ms/avaliação

O fine-tuning **mais que triplicou o acerto exato** (25,5% → 83,0%), e o ganho se mantém no teste manual, com linguagem bem diferente da usada no treino. Ou seja, o modelo não apenas decorou as frases do gerador.

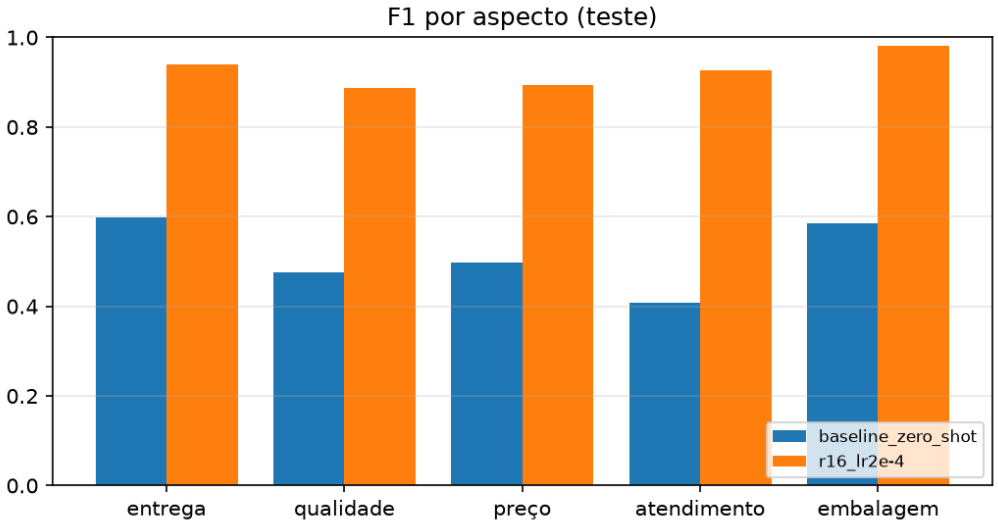
Todos os experimentos

Experimento	r	Camadas	LR	Ép.	Params	Treino	Loss val	Acerto exato	F1 teste	F1 manual	Acerto manual
r16_lr2e-4	16	todas	2e-4	1	17.4M	32 min	0.0004	**83,0%**	**0,926**	**0,913**	**82,5%**
r64_lr2e-4	64	todas	2e-4	1	69.7M	32 min	0.0005	83,2%	0,923	0,878	77,5%
r16_lr2e-4_ep2	16	todas	2e-4	2	17.4M	64 min	0.0002	83,2%	0,920	0,905	82,5%
r16_lr2e-4_attn	16	atenção	2e-4	1	6.4M	25 min	0.0055	82,5%	0,919	0,913	85,0%
r4_lr2e-4	4	todas	2e-4	1	4.4M	29 min	0.0062	80,5%	0,911	0,870	75,0%
r16_lr1e-3	16	todas	1e-3	1	17.4M	32 min	0.0005	76,8%	0,889	0,835	67,5%
r16_lr2e-5	16	todas	2e-5	1	17.4M	30 min	0.0619	61,8%	0,831	0,837	65,0%
baseline_zero_shot	—	—	—	—	—	—	—	25,5%	0,514	0,611	27,5%

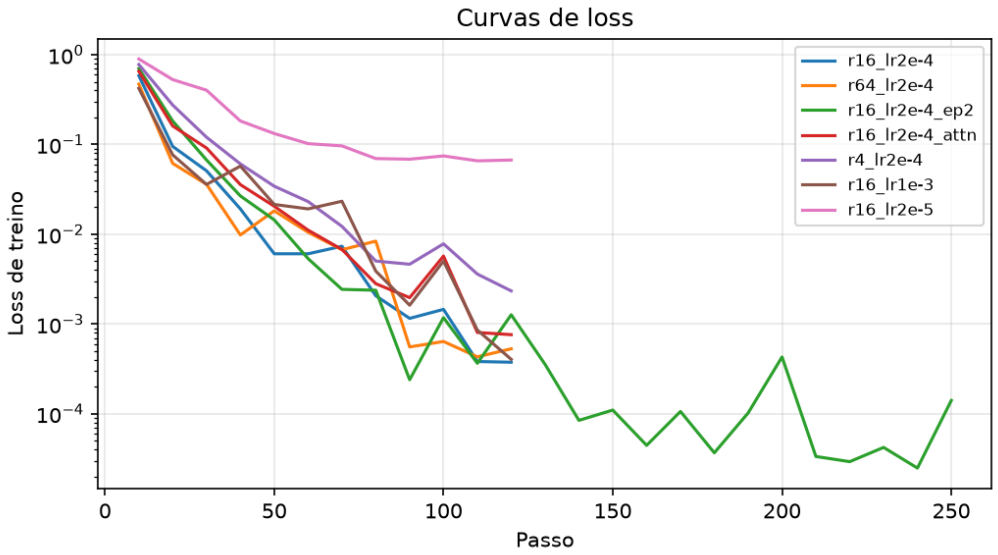
Ordenado pelo F1 dos pares no teste. Tempos de treino na GPU do Apple M5.



Comparação dos experimentos nos dois conjuntos de teste.

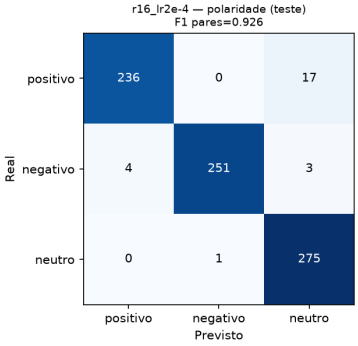


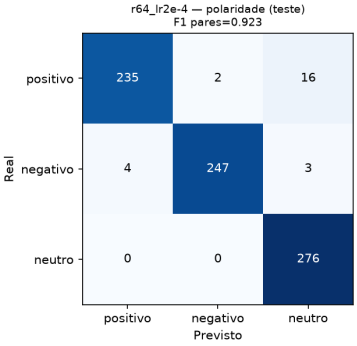
F1 por aspecto: modelo sem treino × melhor modelo.

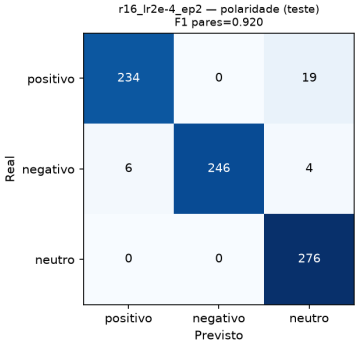


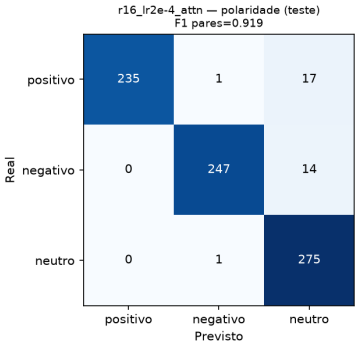
Curvas de loss de treino (escala logarítmica).

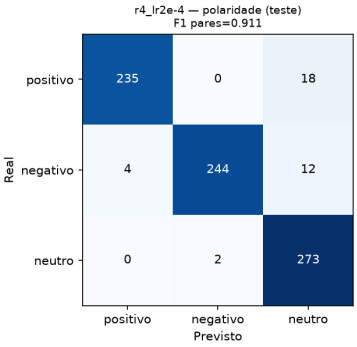
Matrizes de confusão da polaridade (conjunto de teste)

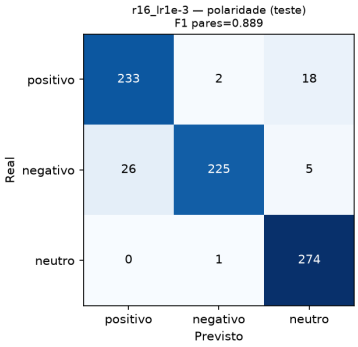


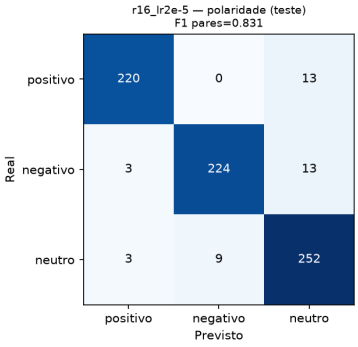


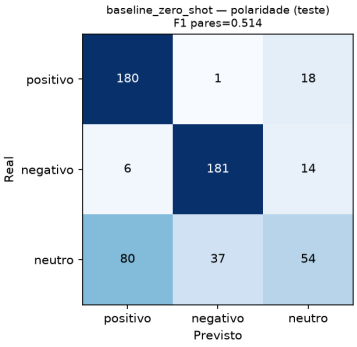












10. Conclusões sobre os parâmetros

- **Learning rate foi o parâmetro mais importante.** Com 2e-5, o modelo mal aprendeu em 1 época (loss de validação 100× maior, acerto exato de 61,8%). Com 1e-3, a loss caiu tanto quanto na referência, mas a generalização piorou (F1 manual de 0,835): o modelo se ajustou demais ao padrão do gerador. **2e-4 foi o melhor equilíbrio.**
- **Rank do LoRA:** r=4 tem pouca capacidade (F1 0,911). r=64 tem 4× mais parâmetros que r=16 e não melhora no teste, além de generalizar pior no teste manual (0,878). **r=16 é o ponto ideal.**
- **Épocas:** a 2ª época dobrou o tempo e reduziu a loss de validação, mas não melhorou o teste. É sinal de que, depois da 1ª época, o modelo passa a decorar o conjunto de treino.
- **Camadas:** LoRA só na atenção, com 37% dos parâmetros e o treino mais rápido (25 min), ficou praticamente empatado com a referência e teve o melhor acerto exato no teste manual (85%). É uma boa opção quando o tempo de GPU é limitado.
- **Loss de validação baixa não garante generalização:** r16_lr1e-3 e r16_lr2e-4_ep2 tiveram as menores losses e não foram os melhores. Por isso a escolha do modelo foi feita pelas métricas de teste, e não pela loss.

11. Avaliação das respostas

Abaixo estão as respostas do modelo sem treino e do modelo treinado para **todas as 40 avaliações do teste manual**. O modelo treinado errou 7, e o modelo sem treino errou 29. ✓ = resposta idêntica à esperada; ✗ = diferente.

#	Avaliação	Esperado	Sem treino		Treinado	
1	Chegou em 3 dias, bem antes do que o site falava. O fone é bom demais, grave forte e confortável.	entrega: pos, qualidade: pos	entrega: pos, qualidade: pos	✓	entrega: pos, qualidade: pos	✓
2	Produto lindo mas a caixa veio toda detonada, sorte que não quebrou nada.	qualidade: pos, embalagem: neg	embalagem: neg	✗	qualidade: pos, embalagem: neg	✓
3	Paguei quase 500 reais nisso e em um mês já tá com mau contato. Não compensa.	qualidade: neg, preço: neg	qualidade: neg, preço: pos	✗	qualidade: neg, preço: neg	✓
4	Liguei 4 vezes no SAC pra trocar e ninguém resolveu, um descaso total.	atendimento: neg	atendimento: neg	✓	atendimento: neg	✓
5	Melhor compra do ano, baratinho e funciona que é uma beleza	qualidade: pos, preço: pos	preço: pos	✗	qualidade: pos, preço: pos	✓
6	demorou 20 dias pra chegar, mas o produto é exatamente como na foto, muito bom	entrega: neg, qualidade: pos	entrega: neg, qualidade: pos	✓	entrega: neg, qualidade: pos	✓
7	Comprei pra minha mãe no dia das mães.	{}	entrega: neu	✗	{}	✓
8	A vendedora tirou todas as minhas dúvidas pelo whatsapp, super educada. Chegou certinho na data combinada.	entrega: neu, atendimento: pos	entrega: pos, atendimento: pos	✗	entrega: neu, atendimento: pos	✓
9	O preço tava igual em todo lugar, comprei aqui pq tinha frete grátis e chegou rápido.	entrega: pos, preço: neu	entrega: pos	✗	entrega: pos, preço: neu	✓
10	veio dentro de um saquinho plástico sem nada de proteção, o vidro rachou	qualidade: neg, embalagem: neg	embalagem: neg	✗	qualidade: neg, embalagem: neg	✓
11	Liquidificador fraco, não tritura gelo direito. Pelo menos foi barato.	qualidade: neg, preço: pos	qualidade: neg, preço: pos	✓	qualidade: neg, preço: pos	✓
12	Entrega no prazo, produto ok. Nada a declarar.	entrega: neu, qualidade: neu	entrega: pos, qualidade: pos	✗	entrega: pos, qualidade: neu	✗
13	O rastreamento dizia entregue mas não recebi nada, e o atendimento só manda mensagem automática.	entrega: neg, atendimento: neg	entrega: neg, atendimento: neg	✓	entrega: neg, atendimento: neu	✗

#	Avaliação	Esperado	Sem treino		Treinado	
14	Que caixa bonita! Dei de presente e todo mundo elogiou a apresentação.	embalagem: pos	embalagem: pos	✓	embalagem: pos	✓
15	custo beneficio otimo, recomendo pra quem quer gastar pouco	preço: pos	{}	✗	preço: pos	✓
16	A cadeira é confortável, montagem fácil, material resistente. Entregue em uma semana, o normal.	entrega: neu, qualidade: pos	qualidade: pos	✗	entrega: neu, qualidade: pos	✓
17	Tive problema com a nota fiscal e o pessoal do suporte resolveu em minutos. Nota mil pro atendimento.	atendimento: pos	atendimento: pos	✓	atendimento: pos	✓
18	Esperava mais pelo valor que paguei. A qualidade é só mediana.	qualidade: neu, preço: neg	qualidade: neg	✗	qualidade: neu, preço: neg	✓
19	Bateria do celular não aguenta meio dia. Horrível.	qualidade: neg	{}	✗	qualidade: neg	✓
20	Chegou super bem embalado, com isopor e plástico bolha, e antes do prazo ainda!	entrega: pos, embalagem: pos	embalagem: pos	✗	entrega: pos, embalagem: pos	✓
21	O tênis é lindo, mas o tamanho veio errado e a loja não quis trocar.	qualidade: pos, atendimento: neg	embalagem: neu	✗	qualidade: pos, atendimento: neg	✓
22	Preço justo, qualidade ok, entrega normal. É o que é.	entrega: neu, qualidade: neu, preço: pos	preço: pos	✗	entrega: neu, qualidade: neu, preço: neu	✗
23	Simplesmente parou de ligar depois de 10 dias de uso.	qualidade: neg	entrega: neu	✗	qualidade: neg	✓
24	a entrega atrasou mt e quando chegou a caixa tava aberta	entrega: neg, embalagem: neg	entrega: neg	✗	entrega: neg, embalagem: neg	✓
25	Comprei na promoção relâmpago, saiu pela metade do preço. O aspirador é potente e silencioso.	qualidade: pos, preço: pos	qualidade: pos, preço: pos	✓	qualidade: pos, preço: pos	✓
26	Fiz a compra pelo app, foi tranquilo.	{}	entrega: neu	✗	atendimento: neu	✗
27	O chat demorou um pouco pra responder mas resolveram meu problema. Produto chegou bem embalado.	atendimento: pos, embalagem: pos	entrega: pos, embalagem: pos	✗	atendimento: neu, embalagem: pos	✗
28	Muito caro pro que é. A panela gruda tudo.	qualidade: neg, preço: neg	qualidade: neg, preço: neg	✓	qualidade: neg, preço: neg	✓
29	Chegou rápido, mas veio a cor errada.	entrega: pos, qualidade: neg	entrega: pos, qualidade: neg, embalagem: neg	✗	entrega: pos, qualidade: neg	✓
30	produto mediano, preço de mercado, nada demais	qualidade: neu, preço: neu	qualidade: neu, preço: neu	✓	qualidade: neu, preço: neu	✓
31	Atendimento impecável desde a venda até a entrega, que foi super rápida.	entrega: pos, atendimento: pos	atendimento: pos	✗	entrega: pos, atendimento: pos	✓
32	Embalagem comum de papelão, chegou sem avarias. O relógio é bonito e funciona bem.	qualidade: pos, embalagem: neu	qualidade: pos	✗	qualidade: pos, embalagem: neu	✓
33	Não chegou até hoje e já se passaram 30 dias. Ninguém me dá retorno.	entrega: neg, atendimento: neg	entrega: neg	✗	entrega: neg, atendimento: neg	✓
34	Ótimo! Uso todos os dias.	qualidade: pos	entrega: neu, qualidade: pos, preço: neu, atendimento: neu, embalagem: neu	✗	{}	✗
35	O valor é alto, mas a qualidade compensa, é muito durável.	qualidade: pos, preço: neg	qualidade: pos, preço: neg	✓	qualidade: pos, preço: neg	✓
36	Meu marido gostou.	{}	entrega: neu, qualidade: neu, preço: neu, atendimento: neu, embalagem: neu	✗	{}	✓

#	Avaliação	Esperado	Sem treino		Treinado	
37	Prazo de entrega longo, 15 dias úteis, mas cumpriram. O livro veio impecável.	entrega: neu, qualidade: pos	entrega: neg, qualidade: pos	✗	entrega: neg, qualidade: pos	✗
38	Embalagem rasgada, produto amassado e o vendedor sumiu.	qualidade: neg, atendimento: neg, embalagem: neg	embalagem: neg	✗	qualidade: neg, atendimento: neg, embalagem: neg	✓
39	Barato, chegou rápido e funciona. Sem do que reclamar.	entrega: pos, qualidade: pos, preço: pos	entrega: pos, preço: pos	✗	entrega: pos, qualidade: pos, preço: pos	✓
40	O suporte me atendeu normalmente, seguiram o procedimento padrão de troca.	atendimento: neu	atendimento: pos	✗	atendimento: neu	✓

pos = positivo · neg = negativo · neu = neutro

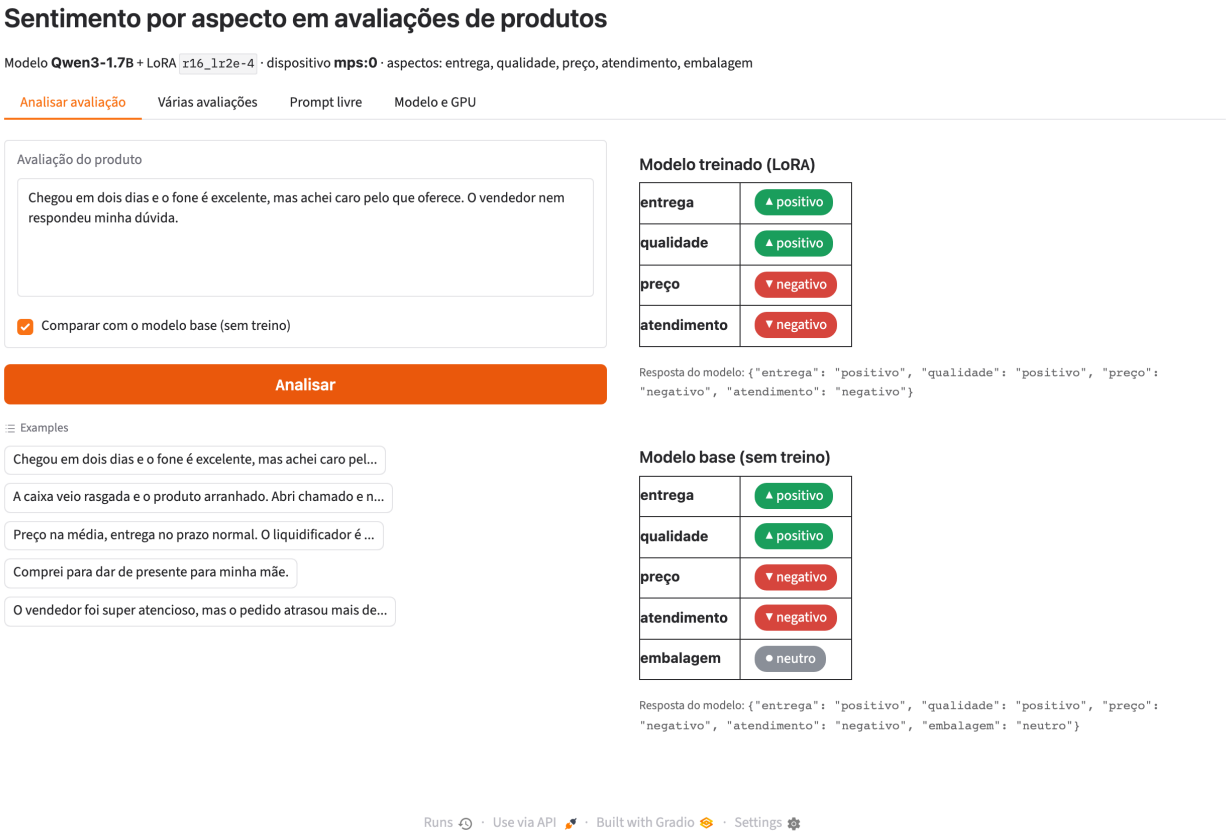
Análise dos erros

- **Modelo sem treino:** omite aspectos claros ("Bateria do celular não aguenta meio dia" → {}), troca polaridade ("Paguei quase 500 reais... Não compensa" → preço: positivo) e lista os 5 aspectos como neutro em avaliações sem nenhum aspecto ("Meu marido gostou.").
- **Modelo treinado:** os 7 erros são, na maioria, casos ambíguos na fronteira do "neutro" ("Entrega no prazo, produto ok" → entrega positivo; "Prazo de entrega longo, mas cumpriram" → entrega negativo).
- **Armadilhas de vocabulário no teste sintético:** a frase "atende o básico" (sobre qualidade) causou 31 dos 34 casos de "qualidade omitida": o modelo associa a palavra "atende" ao aspecto atendimento. Da mesma forma, "é caro demais pelo que **entrega**" faz o modelo marcar também o aspecto entrega. Ou seja, em alguns casos o modelo ainda se apoia em palavras-chave; mais variedade de frases no treino seria o próximo passo.

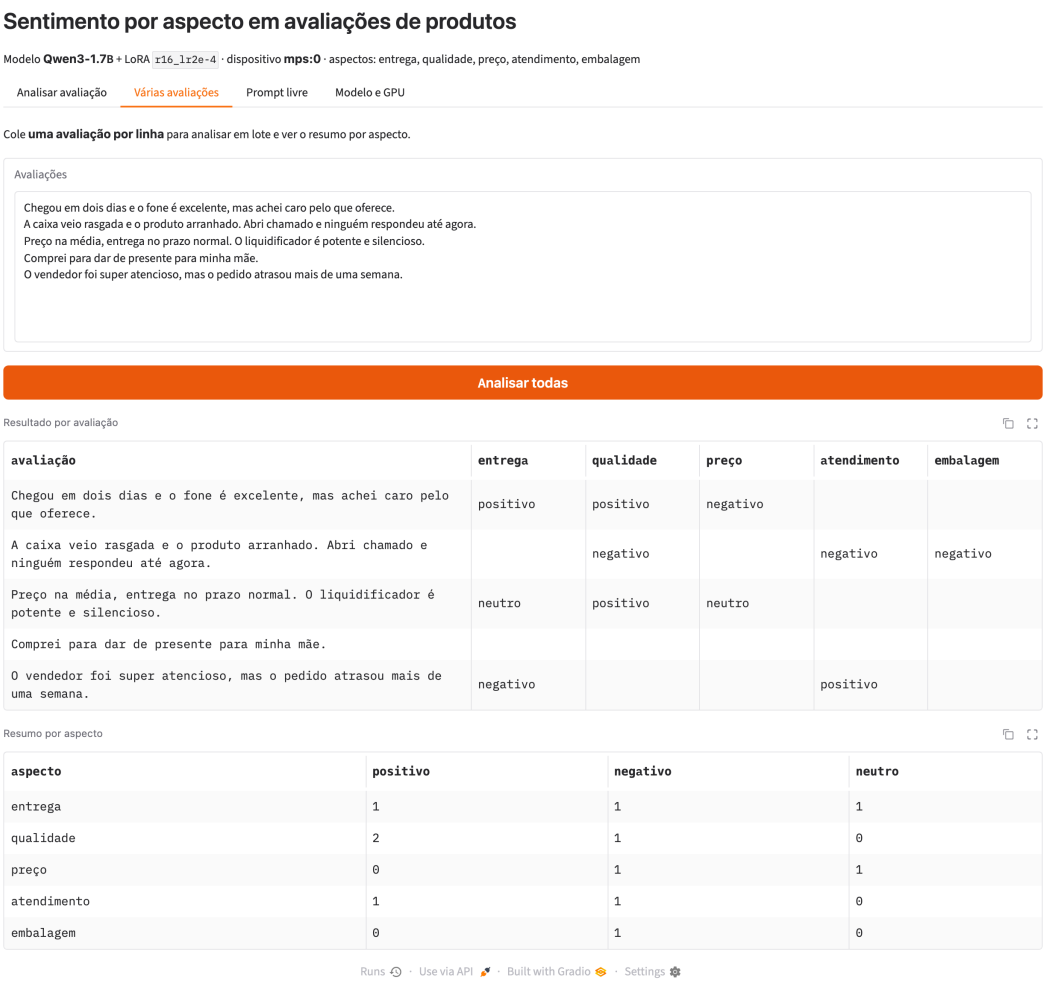
12. Frontend

Interface em **Gradio** (`app/app.py`), com quatro abas:

- **Analisar avaliação:** o usuário digita uma avaliação e vê os aspectos com sentimentos coloridos, lado a lado com a resposta do modelo **sem treino** (o LoRA é desligado na hora, sem carregar outro modelo na memória).
- **Várias avaliações:** uma por linha; mostra uma tabela por avaliação e um resumo por aspecto.
- **Prompt livre:** o usuário cria o próprio prompt (system + mensagem) e ajusta temperatura, top-p, tamanho máximo da resposta e o modo de raciocínio do Qwen3, com a resposta aparecendo em streaming.
- **Modelo e GPU:** informações da GPU e da configuração de treino do adaptador carregado.



Aba "Analisar avaliação": modelo treinado × modelo sem treino. O modelo sem treino inventa o aspecto embalagem, que não é mencionado.



Aba "Várias avaliações": análise em lote e resumo por aspecto.

13. Entregáveis

Tudo o que foi produzido pelo grupo está no repositório do GitHub. As instruções de instalação e execução estão no README do repositório.

Entregável	Descrição	Onde está
Repositório	Código, dados de teste, resultados e documentação	https://github.com/lgustavobarre351/GENERATIVE_AI_CP2-CP3
Modelo treinado	Adaptador LoRA do melhor experimento (r16_lr2e-4), 33 MB, pronto para uso	outputs/r16_lr2e-4/
Frontend	Aplicação Gradio com análise individual, em lote, prompt livre e informações da GPU	app/app.py
Resultados dos experimentos	Tabela comparativa, métricas de cada experimento e log completo da execução na GPU	results/RESULTADOS.md, results/*.json, results/log_execucao.txt
Respostas do modelo	Resposta de cada modelo para cada avaliação dos dois conjuntos de teste	results/*_predicoes.csv
Gráficos	Comparação, F1 por aspecto, curvas de loss e matrizes de confusão	results/*.png
Print da GPU no VSCode	GPU Apple M5 funcionando, com monitor a 98% de uso	docs/img/gpu_vscode.png
Prints do frontend	Análise individual e em lote	docs/img/frontend*.png
Teste manual	40 avaliações escritas à mão pelo grupo, com as respostas esperadas	data/teste_manual.jsonl
Roteiro executável	Notebook com todas as etapas, para rodar no VSCode	notebooks/projeto.ipynb

Entregável	Descrição	Onde está
Guia de GPU	Configuração Metal/CUDA, VSCode e monitoramento	docs/GPU_VSCODE.md
Documentação	README do repositório e este relatório	README.md, docs/Relatorio_CP2_CP3.pdf

14. Limitações e próximos passos

- Dados sintéticos: as frases vêm de um banco finito. O teste com frases inéditas e o teste manual medem a generalização, mas avaliações reais são mais variadas. Próximo passo: rotular uma amostra de avaliações reais.
- "Neutro" é a classe mais subjetiva ("preço razoável" é neutro ou positivo?).
- Aspectos fora da lista (cor, tamanho, garantia...) não são cobertos.
- O modelo ainda se apoia em palavras-chave em alguns casos ("atende", "entrega"); mais variedade de frases no treino deve corrigir.

15. Referências

- Qwen Team. *Qwen3 Technical Report*, 2025. https://huggingface.co/Qwen/Qwen3-1.7B
- Hu, E. et al. *LoRA: Low-Rank Adaptation of Large Language Models*, 2021. https://arxiv.org/abs/2106.09685
- Pontiki, M. et al. *SemEval-2014 Task 4: Aspect Based Sentiment Analysis*, 2014.
- Hugging Face Transformers e PEFT. https://huggingface.co/docs
- PyTorch MPS backend. https://docs.pytorch.org/docs/stable/notes/mps.html